

DATA PREPROCESSING REPORT

Vizabridge

비자·체류 매뉴얼 1 차 데이터 전처리

결 과 보 고 서

외교부 사증·체류민원 안내 매뉴얼 26 컬럼 정형 데이터 구축 작업

주 제	비자·체류 행정 매뉴얼 데이터 전처리 및 정형화
작 업 자	데이터팀 김정환, 김나현
데이터 출처	외교부 「사증민원 안내 매뉴얼」 482 쪽 / 「체류민원 안내 매뉴얼」 383 쪽 (2026.05 판)
산 출 물	사증 158 행 × 26 열 / 체류 275 행 × 26 열 (CSV·Excel)
문서 형식	1 차 데이터 전처리 결과 보고서

목 차

Abstract (요약)	1
제 1 장 서론	2
1.1 작업 배경.....	2
1.2 본 작업의 위치 — 1 차 데이터 전처리	2
제 2 장 최종 컬럼 구성	4
2.1 26 컬럼 한눈에 (카테고리 6 분류).....	4
2.2 컬럼별 생성 이유와 작성 기준	5
제 3 장 데이터 정리 기준 — 주요 컬럼별	9
3.1 신청종류 / 3.2 신청상황 / 3.3 대상자 / 3.4 자격요건	9
3.5 제출서류 / 3.6 제한 / 3.7 예외 / 3.8 키워드	11
제 4 장 작업 중 애매했던 부분	13
4.1 신청상황 vs 대상자.....	13
4.2 사증유효기간 vs 1 회부여 체류기간	14
4.3 매뉴얼이 묶여 서술한 통합행 분리	14
4.4 사증·체류 단계의 혼재.....	15
제 5 장 추가 생성한 컬럼과 이유	16
5.1 매뉴얼에 없거나 우리가 별도 정의한 컬럼.....	16
5.2 챗봇·후속 단계용 메타 컬럼	17
제 6 장 향후 검수 및 보완 필요 사항	18
6.1 추가 확인이 필요한 컬럼	18
6.2 JSON/RAG 변환 시 주의사항	19
【부록 A】 한국 비자 자격 분류 체계	20
【부록 B】 컬럼별 채움률	23
【참고 자료】	24

Abstract

본 보고서는 대한민국 외교부에서 발간한 「사증민원 자격별 안내 매뉴얼」 482 쪽과 「체류민원 자격별 안내 매뉴얼」 383 쪽을 26 개 컬럼의 정형 CSV 로 변환한 1 차 데이터 전처리 작업의 결과를 정리한 문서이다. 작업 결과 사증 매뉴얼 158 행, 체류 매뉴얼 275 행의 데이터셋을 구축하였다.

작업의 핵심 원칙은 「매뉴얼 원문이 ground truth」이며, 매뉴얼이 명시한 정보 단위를 그대로 컬럼으로 환원하는 것이다. 본 단계에서는 임의의 요약·가공 없이 매뉴얼 원문 표현을 보존하였고, 임베딩·검색 인덱스·챗봇 응답과 같은 후속 가공은 별도 단계에서 본 데이터셋을 입력으로 받아 수행하는 것을 전제로 하였다.

본 보고서는 다음 5 가지를 차례로 정리한다. (1) 최종 컬럼 구성과 각 컬럼의 생성 이유, (2) 주요 컬럼의 정리 기준, (3) 작업 중 분류가 애매했던 케이스와 처리 방식, (4) 매뉴얼에 없거나 새로 추가한 컬럼과 그 이유, (5) 향후 검수·JSON/RAG 변환 시 주의해야 할 사항.

【주요어】

비자 행정, 데이터 전처리, 정형 데이터, 외교부 매뉴얼, 출입국관리법, Vizabridge

제 1 장 서 론

1.1 작업 배경

대한민국 외교부는 매년 「사증민원 자격별 안내 매뉴얼」(482 쪽)과 「체류민원 자격별 안내 매뉴얼」(383 쪽)을 발간하여 행정 일선에서의 일관된 처리 기준을 제공한다. 두 매뉴얼은 A-1(외교)부터 H-2(방문취업)까지 35 종 이상의 비자 자격과 각 자격의 하위 약호(sub-code)·협정·시범사업에 대한 발급 기준·자격요건·제출서류·절차를 망라한다.

그러나 총 865 쪽에 달하는 PDF 매뉴얼을 외국인 신청자나 행정 담당자가 직접 검색하기에는 한계가 있고, 매년 개정되면서 신규 트랙(K-point E-7-4, K-STAR, 광역형 비자 등)이 지속적으로 추가된다. 비자 행정 챗봇 Vizabridge 는 사용자가 자연어로 질문하면 정확한 행정 정보를 제공하는 것을 목표로 하며, 본 작업은 그 데이터 소스를 구축하는 작업에 해당한다.

1.2 본 작업의 위치 — 1 차 데이터 전처리

본 작업은 Vizabridge 시스템 전체 파이프라인에서 「1 차 데이터 전처리」 단계에 해당한다. 이 단계의 목표는 비구조화 PDF 를 사람·기계 모두 검증 가능한 정형 CSV 로 환원하는 것이며, 본 단계의 산출물은 이후 단계의 입력값이 된다.

단계	역할	산출물	본 작업의 위치
1 차 전처리	PDF → 정형 CSV (의미 구조 환원)	26 컬럼 CSV (사증 158 행 / 체류 275 행)	★ 본 작업
2 차 가공	청크화·임베딩·검색 인덱스 구축	벡터 DB / 검색 인덱스	후속 단계
3 차 운영	챗봇 응답·grounding·피드백	답변·인용 / 사용자 로그	후속 단계

[표 1-1] Vizabridge 데이터 파이프라인에서 본 작업의 위치

이 위치 인식이 작업 방향을 결정하였다. 본 단계에서는 매뉴얼 원문 표현을 임의로 요약·가공하지 않고, 정보 단위만 컬럼으로 환원하는 데 집중하였다. 가공·요약은 2 차 이후 단계에서 본 데이터셋을 입력으로 받아 수행되어야 한다고 판단하였기 때문이다.

제 2 장 최종 컬럼 구성

2.1 26 컬럼 한눈에 — 카테고리 6 분류

매뉴얼이 반복적으로 사용하는 정보 단위를 분석하여 26 개 컬럼을 6 개 카테고리로 그룹핑하였다.

카테고리	컬럼 (개수)	역할
식별·자격	비자코드, 상위코드, 사증·체류, 신청종류, 키워드 (5)	행 식별·분류 메타
신청 조건	신청상황, 대상자, 자격요건 (3)	누가·언제·어떤 조건으로
기간	사증유효기간, 1 회부여 체류기간, 체류상한 (3)	비자의 시간 단위
절차·서류	절차, 수수료, 추천·승인기관, 의무사항, 제출서류, 점수표 (6)	처리 절차와 필요 서류
관계·제한	쿼터, 초청자, 예외, 제한, 선행자격, 다음단계, 동반가족 (7)	자격 간 관계 및 제한
메타	예상질문, 출처 (2)	검색·검증용 메타

[표 2-1] 26 컬럼 카테고리 6 분류

2.2 컬럼별 생성 이유와 작성 기준

각 컬럼이 왜 만들어졌고 어떻게 채웠는지를 한 표로 정리하면 다음과 같다.

#	컬럼	왜 만들었나	어떻게 채웠나
1	비자코드	행이 다루는 가장 구체적인 비자 약호 식별	매뉴얼이 명시한 약호만 그대로 (예: A-1, C-3-3, D-8-4S)
2	상위코드	sub-code 의 상위 분류 별도 보관	sub-code 인 경우 상위 자격까지만 (C-3-3 → C-3)
3	사증·체류	행정 단계(사증 발급 / 체류 행정) 구분	2 값 enum. 행 단위로 단계 명시 (매뉴얼 단위 무관)
4	신청종류	행이 다루는 행정행위 종류	매뉴얼 용어 그대로 enum 화 (사증발급, 체류자격 변경, 외국인등록 등)
5	키워드	챗봇 검색 매칭용 단어·일상어	공식 용어 + 일상어 (외교관·대사·외교사절단 등)
6	신청상황	「언제·어떤 케이스에서」 신청이 일어나는지	상황·시점·트리거 조건만 (예: 출생일부터 90 일 이내)

7	대상자	「누가」 이 자격을 받는 사람인가	사람의 카테고리만 (예: 외교사절단 구성원)
8	자격요건	대상자가 충족해야 하는 정량·정성 요건	GNI 배수, 학위, 경력, 점수 등
9	사증유효기간	비자 발급일로부터 입국 가능한 기한	발급일~입국기한 (예: 유효기간 1 년 복수)
10	1 회부여 체류기간	입국 후 1 회 부여받는 체류 길이	입국 후 부여값 (예: 인증대학 2 년)
11	체류상한	해당 자격으로 총 체류 가능한 상한	연장 누적 상한
12	절차	신청·발급·허가의 단계별 행위	"재외공관 신청 → 발급 → 입국" 흐름
13	수수료	신청·발급 수수료 금액	원화 단위, 면제 표기 (예: 4 만원, GKS 면제)
14	추천·승인기관	신청 전 필요한 추천·승인 기관	외교부, 출입국·외국인청, 광역지자체장 등
15	의무사항	신청자가 이행해야 할 의무	"외국인등록 시 안내문 교부·서명·제출" 등
16	제출서류	신청 시 필요 서류 목록	[필수서류] / [선택서류] 라벨, ①②③ 번호 보존
17	점수표	점수제 자격의 항목·배점	E-7-4 K-point, F-2-7 거주 점수제 등에만 적용
18	쿼터	연간 발급 인원 제한	"광역형 D-2 인천 60 명, 충북 830 명" 등
19	초청자	초청 주체 (기관·기업·개인)	주로 사증 단계 ("고용주 기업", "국내 대학")
20	예외	일반 규칙의 예외 조항	결핵 고위험국가 35 개국, 상호주의 적용 29 개국 등
21	제한	자격 변경·신청 제한 사항	"D-3-E-9-E-10-G-1 일부 변경 제한" 등
22	선행자격	이 자격 신청 전 단계 자격	변경·연장 행의 핵심 ("F-4 자격 2 년+ 체류" 등)
23	다음단계	이후 변경 가능한 후속 자격	F-5 는 시행령 별표 1 의 3 호수 함께 명시
24	동반가족	이 자격 보유자의 가족이 받는 자격	"F-3 (배우자·미성년 자녀)" 등
25	예상질문	이 행에 해당하는 사용자 질문 예시	챗봇 학습·매칭용 자연어 질문
26	출처	PDF 매뉴얼 페이지 번호	"A-1 외교 / 사증발급 (p. 7~8)" 식

[표 2-2] 26 컬럼 전체 — 생성 이유와 작성 기준

제 3 장 데이터 정리 기준 — 주요 컬럼별

이 장에서는 작성자가 가장 자주 혼동할 수 있는 8 개 주요 컬럼에 대해 「어떤 기준으로 데이터를 구분하고 채웠는가」를 정리한다.

3.1 신청종류

「이 행이 다루는 행정행위가 무엇인가」를 매뉴얼이 사용하는 행정 용어로 enum 화하였다. 임의의 새 용어를 만들지 않고 매뉴얼 표현을 그대로 사용하였다.

- 사증발급 / 사증발급인정서 (**사증 단계**)
- 체류자격 변경 / 체류기간 연장 / 체류자격 부여 / 체류자격외 활동허가 (**체류 단계**)
- 외국인등록 / 재입국허가 / 근무처 변경·추가 (**체류 절차**)
- **공통사항** (특정 자격에 매이지 않는 행 — 심사수수료·여권·결핵진단 등)

3.2 신청상황

「언제·어떤 케이스에서」 이 신청이 일어나는가를 적었다. 사람의 카테고리(예: 외교사절단)는 신청상황이 아니라 대상자 컬럼으로 분리한다.

예) "출생일부터 90 일 이내 신청" (체류자격 부여) / "농어번기 일손부족 해결을 위한 8 개월 고용" (E-8 계절근로)

3.3 대상자

「누가」 이 자격을 받는 사람인지를 사람 카테고리·주체만으로 적었다. 충족해야 할 조건은 자격요건 컬럼으로 분리한다.

예) "외국정부의 외교사절단/영사기관 구성원" (A-1) / "F-4 자격자의 부모" (F-1)

3.4 자격요건

대상자가 충족해야 하는 정량·정성 요건이다. 매뉴얼이 표·각주로 명시한 숫자·기준은 모두 보존한다.

예) "GNI 3 배 이상, 박사 학위, 경력 5 년 이상" (Top-Tier) / "가구원수별 소득기준 (2 인 25,195,752 원...)" (F-6-1)

3.5 제출서류

매뉴얼의 ①②③ 번호 형식과 [필수서류] / [선택서류] 라벨을 그대로 보존한다. 임의로 서류명을 축약·치환하지 않는다.

예) "[필수서류] ① 사증발급신청서·여권·사진·수수료 / ② 파견·재직 증명 / ③ 동반가족 가족관계 입증서류"
(A-1)

3.6 제한

자격 변경·신청·발급이 막혀 있는 케이스를 적는다. 매뉴얼이 「제한」, 「불가」, 「~을 제외하고는 변경할 수 없다」고 명시한 부분만 보존한다.

예) "D-3-E-9E-10-G-1 일부 변경 제한" / "H-2 → F-4 전환 시 단순노무 직종 취업 불가"

3.7 예외

일반 규칙의 예외 조항을 적는다. 「제한」이 「불가」를 명시한다면, 「예외」는 「일반 규칙에도 불구하고 ~인 경우는 허용/특례」를 명시한다.

예) "결핵 고위험국가 35 개국에 한해 결핵진단서 추가 제출" / "상호주의 적용국 29 개국 비자 면제"

3.8 키워드

챗봇이 사용자 자연어 질의와 행을 매칭하기 위한 단어 목록이다. 매뉴얼의 공식 용어뿐 아니라 일반 사용자가 쓸 법한 일상어·속어를 함께 수록한다.

예) A-1 → "외교관, 대사, 외교사절단" / D-2 → "유학생, 학생비자, 대학생, 어학연수"

제 4 장 작업 중 애매했던 부분

작업 과정에서 매뉴얼의 서술 방식 자체가 모호하여 컬럼 분류가 까다로웠던 케이스와 우리가 적용한 처리 방식을 정리한다.

4.1 신청상황 vs 대상자

두 컬럼은 의미가 다르지만, 매뉴얼이 한 문장에 「누구에게」와 「어떤 조건으로」를 묶어 서술하는 경우가 많아 작성 시 가장 자주 혼동된다. 다음 4 가지 기준으로 처리하였다.

기준	적용 상황	신청상황	대상자
기준 1	한 문장에 사람+조건이 묶임 (사증발급 다수)	발급 시나리오 중심	사람 카테고리 위주, 조건은 자격요건
기준 2	명확한 분리 가능 (자격 변경·부여)	트리거 조건 (예: 출생 90 일 이내)	상위 비자코드에서 추론 가능하면 비움
기준 3	절차 행 (연장·등록·재입국)	행위 트리거만 간단히	대부분 비움 (상위 비자코드에서 추론)
기준 4	메타·공통 행	적용 범위·상황	적용 대상 자격 명단

[표 4-1] 신청상황 vs 대상자 채움 4 기준

4.2 사증유효기간 vs 1 회부여 체류기간

두 컬럼은 정의가 다르지만 문자열이 비슷해 작성자가 같은 값을 두 칸에 동시 기재하기 쉬웠다. 다음과 같이 정의를 명확히 구분하였다.

- 사증유효기간 = 「비자 발급일로부터 입국 가능한 기한」 (예: 1 년 복수, 3 월 단수)
- 1 회부여 체류기간 = 「입국 후 1 회 부여받는 체류 길이」 (예: 90 일 이하, 최대 2 년)

예) D-2 유학 — 사증유효기간 "1 년 복수" / 1 회부여 체류기간 "인증대학 2 년, 일반대학 1 년"

4.3 매뉴얼이 묶어 서술한 통합행 분리

매뉴얼은 가독성을 위해 같은 자격 안에 여러 발급 기준을 한 챕터에 묶어 서술한다. 우리는 매뉴얼이 별도 번호·섹션으로 구분한 발급 기준은 별도 행으로 분리하여 각 기준의 첨부서류·체류기간·대상자가 정확히 추적되도록 하였다. 총 24 건의 통합행을 매뉴얼 원문 구조 기준 93 행으로 재구성하였다.

분리 사례	원본	→ 분리 결과
국가별	C-3 복수사증	중국 / 한·몽골 / 동남아 / 자원외교 4 행
분야별	C-4-5 단기취업	첨단기술 / 수입기계 / 영어캠프 / 일시휴행 / 단기 강의 / 기타 6 행
협정별	D-7 주재	외국지사 / 해외진출 / 한·러 / 한·우즈벡 / 한·인도 5 행
지역별	D-2 광역형	인천 / 광주 / 강원 / 충북 / 충남 / 전북 6 행
Sub-code 별	D-10-1 변경	점수제 적용 + 면제 7 개 카테고리 8 행

[표 4-2] 통합행 분리 주요 사례

4.4 사증·체류 단계의 혼재

사증 매뉴얼이라도 일부 자격은 사증발급이 불가하고 체류자격 변경만 허용된다(예: E-7-4 K-point). 반대로 체류 매뉴얼에 사증발급인정서 기준이 포함된 챕터도 있다. 즉 「사증 단계인가, 체류 단계인가」가 매뉴얼 문서 단위로 깔끔하게 구분되지 않는다.

이에 우리는 「사증·체류」 enum 컬럼을 두어 행 단위로 단계를 명시하고, 어느 매뉴얼에서 발췌했는지와 무관하게 실제 행정 단계를 정확히 기록하였다.

이 외에도 비자코드와 상위코드의 분리 (긴 설명문을 비자코드 칸에 넣는 실수), 추천·승인기관과 초청자의 혼동 등이 작업 초기 자주 발견되었으며 모두 정의를 명확히 한 뒤 정정하였다.

제 5 장 추가 생성한 컬럼과 이유

외교부 매뉴얼은 가독성을 위해 일부 정보를 명시적으로 분리하지 않거나, 챗봇 검색에 필요한 정보를 별도로 제공하지 않는다. 우리는 다음과 같이 매뉴얼에 명시되지 않은 컬럼을 별도로 정의하여 추가하였다.

5.1 매뉴얼에 없거나 우리가 별도 정의한 컬럼

컬럼	왜 추가했나	어떤 경우에 사용하는가
비자코드 / 상위코드	매뉴얼은 「C-3 (C-3-3)」 식으로 sub-code 와 상위 자격을 한 셀에 표기하는 경우 다수. 검색·필터에 부적합.	sub-code 행은 비자코드에 "C-3-3", 상위코드에 "C-3"를 별도로 명시. 챗봇 검색 시 두 단계 모두 매칭 가능.
사증·체류	매뉴얼이 어느 문서에서 왔는지와 실제 행정 단계가 일치하지 않는 경우가 있어 단계 정보가 누락됨.	행 단위로 "사증" / "체류" 2 값 enum 부여. E-7-4 처럼 사증 매뉴얼에 있어도 체류만 허용되는 행은 "체류"로 기재.
신청종류	매뉴얼은 챕터 제목으로만 절차를 구분하므로, 행 단위 행정행위 정보가 없음.	"사증발급", "체류자격 변경", "체류기간 연장", "외국인등록", "공통사항" 등 enum 으로 행 분류. 챗봇이 "변경하려면" 같은 질의에 답할 수 있도록 함.
선행자격	매뉴얼은 자격 변경 행에서 「이전에 어떤 자격이었어야 하는가」를 본문 곳곳에 분산 서술. 단일 컬럼 없음.	변경·연장·영주 트랙 행의 핵심 컬럼. 예: F-5-6 영주 → 선행자격 "F-4 자격 2 년 이상 체류"
다음단계	매뉴얼은 각 자격에서 변경 가능한 후속 자격을 별도 컬럼으로 두지 않음.	챗봇이 「이 자격에서 어디로 갈 수 있나」에 답하기 위한 컬럼. F-5 트랙은 시행령 별표 1 의 3 호수를 함께 명시. 예: "F-5-5 (별표 1 의 3 3 호)"
동반가족	매뉴얼은 가족 동반 자격을 본문 안에 산문으로 서술. 별도 컬럼 없음.	"F-3 (배우자·미성년 자녀)", "F-1 (부모)" 식으로 단순화하여 별도 컬럼으로 분리.

[표 5-1] 매뉴얼에 없거나 우리가 별도 정의한 컬럼

5.2 챗봇·후속 단계용 메타 컬럼

컬럼	왜 추가했나	어떤 경우에 사용하는가
키워드	공식 용어와 사용자가 실제 쓰는 일상어가 다른 경우가 많음 (예: A-1 외교 vs "외교관", D-2 유학 vs "학생비자").	챗봇 검색·매칭용 단어 목록. 공식 용어 + 일상어·속어를 함께 수록. 후속 단계 임베딩 시 보조 매칭 신호로 활용.
예상질문	챗봇 학습 데이터로 사용할 자연어 질의 예시가 매뉴얼에는 없음.	행마다 "D-2 유학생 연장은 언제 신청하나요?" 식의 사용자 질의 예시를 1~3 개 작성. 학습·매칭 데이터 시드로 활용.
출처	매뉴얼 페이지 정보가 행 단위로 보존되어야 챗봇 응답에 출처 인용이 가능.	"A-1 외교 / 사증발급 (p. 7~8)" 식으로 매뉴얼 페이지 명시. 챗봇 응답 grounding 에 그대로 활용 가능.

[표 5-2] 챗봇·후속 단계용 메타 컬럼

제 6 장 향후 검수 및 보완 필요 사항

6.1 추가 확인이 필요한 컬럼

최종본 기준으로 다음 컬럼은 추가 확인 또는 보강이 필요하다.

매뉴얼	컬럼	채움률	검토 방향
사증	의무사항	1.3%	사증 단계는 매뉴얼이 명시한 의무사항이 적음 — 정상 가능 / 최종 확인 필요
사증	수수료	3.2%	매뉴얼 본문 곳곳에 산재한 수수료 정보의 추가 발체 필요
체류	초청자	2.2%	체류 단계엔 초청자가 일반적으로 적용되지 않음 — 컬럼 자체 삭제 여부 재검토
체류	추천·승인기관	9.1%	매뉴얼에서 추천기관 정보가 다른 컬럼에 잘못 들어간 흔적 (misplacement) — 매뉴얼 재대조 후 보강 권장

[표 6-1] 채움률이 낮은 컬럼과 검토 방향

이와 별개로 매뉴얼은 매년 개정되므로 다음 사항도 정책으로 수립되어야 한다.

- 개정분 식별을 위한 출처 페이지 메타데이터 보존
- 변경분만 갱신 vs 전체 재정리 방식의 결정
- 개정 전후 변경 로그 보존

6.2 JSON/RAG 변환 시 주의사항

본 데이터셋은 1 차 전처리의 결과물이며, 후속 단계(임베딩·검색 인덱스·챗봇 응답)에서 다음 사항이 고려되어야 한다.

- 표 형태 데이터(F-6-1 가구원수별 소득기준표, E-7-S2 첨단산업 점수표, E-7-4 K-point 점수표 등)는 행 본문 안에 텍스트로 들어가 있으므로, RAG 체크 분할 시 별도 검색 단위로 분리 권장
- 멀티홉 질의(예: "D-2 유학 → F-5 영주까지의 경로")에 답하려면 선행자격·다음단계 컬럼을 따라가는 그래프 탐색 로직이 필요. 단일 행 검색만으로는 답하기 어려움
- 「출처」 컬럼의 매뉴얼 페이지 정보는 챗봇 응답의 grounding("외교부 매뉴얼 p. 215 참조")에 그대로 활용 가능

- 「예상질문」 컬럼은 사용자 자연어 질의와 행을 매칭하는 학습/검색 보조 데이터로 직접 활용 가능
- F-5 영주 18 개 트랙과 F-2 거주 12 종은 시행령 별표 1 의 3·별표 1 의 2 의 호수로 식별되므로, 검색 인덱스에 호수를 별도 필드로 분리 보관 권장
- 「제한」·「예외」 컬럼은 사용자의 부정형 질의("이 비자에서 안 되는 것은?")에 대응하기 위한 핵심 필드이므로, 임베딩 시 가중치 보강 검토

본 보고서는 1 차 데이터 전처리의 결과를 정리한 문서입니다.

6.2 주의사항에 대하여 보충 설명 남겨드립니다.

CSV는 한 비자 = 한 행 구조인데, 어떤 행은 「표」를 컬럼 안에 텍스트로 통째로 갖고 있습니다.

F-6-1 자격요건 컬럼 = 「2 인 25,195,752 원 / 3 인 32,154,216 원 / 4 인 38,968,428 원...」 가구원수별
표 E-7-4 K-point 점수표 컬럼 = 「한국어 30 점 / 학력 25 점 / 경력 20 점...」 항목별 배점표 왜
문제인가 RAG(검색증강생성)란 챗봇이 답할 때 관련 정보를 먼저 검색해서 그걸 바탕으로 답하는
방식인데, 검색 단위(청크)가 너무 크면 사용자가 "3 인 가구원 소득기준?"이라고 물어도 표 전체가
통째로 끌려오고 다른 6 인·7 인 정보도 같이 답에 섞일것같아 참고사안 남겨드립니다.

② 멀티홉 질의 — 그래프 탐색 로직 필요 무슨 얘기인가 멀티홉(multi-hop) = 한 번에 답이 안
나오고 여러 단계를 따라가야 하는 질문. 예: "D-2 유학생인데 영주까지 어떻게 가나요?" 답: D-2 →
D-10 → E-7 → F-2-7 → F-5-16 (5 단계) 왜 문제인가 우리 CSV에서 D-2 행 하나만 검색해서는
영주까지의 전체 경로를 알 수 없습니다. D-2 행의 「다음단계」 컬럼을 보고 → D-10 행을 또 찾고 →
D-10 의 「다음단계」를 또 보고... 이런 식으로 자격 간 관계를 따라가는 코드가 별도로 필요합니다.
후속 단계에서 할 일 자격을 노드(점)·관계를 엣지(선)로 보는 그래프 구조를 만들어서, 「출발 자격 →
목적 자격」 경로 탐색 함수를 구현해야 합니다. 단순 벡터 검색만으론 불충분하다고 생각이 듭니다.

⑤ 시행령 별표 호수 → 별도 필드로 무슨 얘기인가 F-5 영주는 18 가지 트랙(F-5-1, F-5-5, F-5-6...)이 있고, 각 트랙은 출입국관리법 시행령 별표 1 의 3 에 「1 호, 2 호, 3 호...」로 명시됩니다. F-5-5 = 별표 1 의 3 3 호 (고액투자자) F-5-24 = 별표 1 의 3 15 호 (기술창업) 우리는 다음단계 컬럼에 "F-5-5 (별표 1 의 3 3 호)" 식으로 함께 적었습니다. 왜 중요한가 "별표 1 의 3 3 호 트랙이 뭔가요?" 같은 법령 기준 질의가 오면, 호수가 텍스트에 묻혀 있으면 검색 정확도가 떨어집니다. 호수를 별도 필드(예: byeolpyo_ho: "3 호")로 빼두면: 법령 기준 질의에 정확 매칭 시행령 개정 시 호수 매핑이 쉬워짐 후속 단계에서 할 일 JSON 변환 시 「다음단계」 텍스트에서 "별표 1 의 3 N 호" 패턴을 정규식으로 뽑아내서 별도 필드로 저장

⑥ 제한·예외 컬럼 → 부정형 질의 가중치 보강 무슨 얘기인가 부정형 질의 = 「할 수 없는 것」, 「안 되는 것」을 묻는 질문. "E-9 비전문취업으로 F-4 변경 가능한가요?" → 답: 불가 "H-2 비자로 단순노무 외 다른 직종 가능?" → 답: 불가 왜 문제인가 임베딩(embedding) = 텍스트를 숫자 벡터로 바꿔서 의미 유사도를 비교하는 기술. 긍정형 표현(자격요건, 활동범위)은 잘 매칭되지만 부정형 표현(제한, 예외)은 표현이 모호해서 매칭이 약합니다. 사용자가 "안 되나요?"라고 물어도 챗봇이 자격요건만 가져와서 엉뚱한 답을 할 수 있습니다. 후속 단계에서 할 일 옵션 A: 임베딩 시 「제한」·「예외」 컬럼 가중치를 1.5~2 배로 부여 옵션 B: 부정형 질의를 의도 분류로 먼저 감지 → 이 두 컬럼만 우선 검색 가중치(weighting) = 어떤 정보를 더 중요하게 보겠다는 점수 부여

【부록 A】 한국 비자 자격 분류 체계

본 데이터셋이 다루는 비자 자격은 출입국관리법 시행령 별표 1.1 의 2.1 의 3 에 따라 분류된다.

자격	명칭	활동범위	비고
A-1	외교	외국정부 외교사절단·영사기관 구성원 및 가족	재임 기간
A-2	공무	외국정부·국제기구 공무 수행	재임 기간
A-3	협정	협정에 의해 입국하는 자	Fulbright A-3-99 포함
B-1	사증면제	협정에 의해 사증 면제	90 일 이하
B-2	관광·통과	90 일 이하 단기 관광·통과	90 일 이하
C-1	일시취재	단기 취재·보도 활동	90 일 이하
C-3	단기방문	관광·친지방문·상용·의료관광	10 개 sub-code
C-4	단기취업	90 일 이하 단기 취업	계절근로 C-4-1~4, C-4-5
D-1	문화예술	비영리 학술·예술 활동	2 년 상한
D-2	유학	전문대학 이상 정규교육	8 개 sub-code
D-3	기술연수	해외투자기업 기술연수	2 년
D-4	일반연수	어학·기타 연수	2 년
D-5	취재	외국 보도기관 파견	2 년
D-6	종교	종교 활동	2 년
D-7	주재	외국기업 국내지사 주재	협정 트랙 포함
D-8	기업투자	외국인투자기업 전문인력	5 개 sub-code
D-9	무역경영	회사 경영·무역	2 년
D-10	구직	E 계열 취업을 위한 구직활동	D-10-1·2·3·T
E-1	교수	전문대학 이상 교수	5 년
E-2	회화지도	외국어 회화지도	2 년
E-3	연구	자연과학·고도기술 연구	5 년
E-4	기술지도	기술 제공·지도	5 년
E-5	전문직업	변호사·의사 등	5 년
E-6	예술흥행	음악·미술·문학·연예·운동	2 년
E-7	특정활동	법무부장관 지정 특정활동	67+개 직종
E-8	계절근로	농어업 8 개월 단기 계절근로	8 개월
E-9	비전문취업	고용허가제 17 개국 단순노무	3 년+1 년 10 개월
E-10	선원취업	선박 승무원	3 년
F-1	방문동거	친척방문·가족동거	2 년
F-2	거주	영주 전 단계 장기체류	별표 1 의 2 가~파목
F-3	동반	D~E 자격자의 배우자·미성년 자녀	주체류자 만료일 동일

F-4	재외동포	외국적 동포	3 년
F-5	영주	영주권자	18 개 트랙, 별표 1 의 3
F-6	결혼이민	한국인 배우자	F-6-1·2·3
G-1	기타	A~F·H 에 해당하지 않는 인정자	G-1-1·5·6·10 등
H-1	관광취업	워킹홀리데이	협정국 18~30 세
H-2	방문취업	외국국적동포 단순노무	2026.2.12 신규 발급 중단

[표 A-1] 한국 비자 자격 분류 체계 (출입국관리법 시행령 별표 1·1 의 2·1 의 3)

【부록 B】 컬럼별 채움률

최종 데이터셋의 컬럼별 채움률은 다음과 같다. 채움률이 낮은 컬럼은 6.1 절 검토 방향을 참고할 것.

컬럼	사증 (158 행)	채움률	체류 (275 행)	채움률
비자코드	158	100.0%	275	100.0%
상위코드	158	100.0%	275	100.0%
사증·체류	158	100.0%	275	100.0%
신청종류	158	100.0%	275	100.0%
출처	158	100.0%	275	100.0%
선행자격	158	100.0%	271	98.5%
다음단계	158	100.0%	270	98.2%
동반가족	158	100.0%	267	97.1%
키워드	158	100.0%	275	100.0%
예상질문	153	96.8%	244	88.7%
신청상황	147	93.0%	196	71.3%
자격요건	139	88.0%	213	77.5%
제출서류	125	79.1%	220	80.0%
초청자	101	63.9%	6	2.2%
절차	97	61.4%	87	31.6%
1 회부여 체류기간	93	58.9%	71	25.8%
대상자	89	56.3%	104	37.8%
사증유효기간	88	55.7%	12	4.4%
추천·승인기관	78	49.4%	25	9.1%
체류상한	74	46.8%	74	26.9%
제한	74	46.8%	126	45.8%
예외	63	39.9%	100	36.4%
쿼터	13	8.2%	21	7.6%
점수표	12	7.6%	23	8.4%
수수료	5	3.2%	35	12.7%
의무사항	2	1.3%	59	21.5%

[표 B-1] 26 컬럼 전체 채움률

【 참고 자료 】

【 1 차 자료 】

- 외교부, 「사증민원 자격별 안내 매뉴얼」, 2026.05 판, 482 쪽
- 외교부, 「체류민원 자격별 안내 매뉴얼」, 2026.05 판, 383 쪽

【 관련 법령 】

- 출입국관리법
- 출입국관리법 시행령 별표 1 (체류자격)
- 출입국관리법 시행령 별표 1 의 2 (거주 F-2 활동범위)
- 출입국관리법 시행령 별표 1 의 3 (영주 F-5 자격해당자)

【 산출물 】

- 사증매뉴얼_최종_26col.csv / .xlsx (158 행 × 26 컬럼)
- 체류매뉴얼_최종_26col.csv / .xlsx (275 행 × 26 컬럼)
- Vizabridge_데이터전처리_결과보고서.docx (본 문서)